

La tarea de clasificación en detalle (I)

Alfredo Cuesta Infante

E. T. S. Ingeniería Informática
Universidad Rey Juan Carlos

Master Univ. en Visión Artificial
Reconocimiento de Patrones

Formulación del
problema de
optimización
Regresión lineal
Regresión logística
Notación
n-dimensional
Función de coste
Método de
optimización
Criterio de parada
Regularización
Ajuste fino de modelos
Medidas de bondad
Tabla de Confusión
Precision, Recall,
F-score
Curva ROC

Formulación del problema de optimización

- Regresión lineal
- Regresión logística
- Notación n-dimensional
- Función de coste
- Método de optimización
- Criterio de parada
- Regularización

Formulación del
problema de
optimización

- Regresión lineal
- Regresión logística
- Notación
n-dimensional
- Función de coste
- Método de
optimización
- Criterio de parada
- Regularización

Ajuste fino de modelos

Ajuste fino de modelos

Medidas de bondad

- Tabla de Confusión
- Precision, Recall,
F-score
- Curva ROC

Medidas de bondad

- Tabla de Confusión
- Precision, Recall, F-score
- Curva ROC

Formulación del problema de optimización

- Regresión lineal
- Regresión logística
- Notación n-dimensional
- Función de coste
- Método de optimización
- Criterio de parada
- Regularización

Formulación del
problema de
optimización

- Regresión lineal
- Regresión logística
- Notación
n-dimensional
- Función de coste
- Método de
optimización
- Criterio de parada
- Regularización

Ajuste fino de modelos

Ajuste fino de modelos

Medidas de bondad

- Tabla de Confusión
- Precision, Recall,
F-score
- Curva ROC

Medidas de bondad

- Tabla de Confusión
- Precision, Recall, F-score
- Curva ROC

Regresión lineal

¿Podemos clasificar con regresión?





Figura: (Arriba.) Regresión lineal con 1 sola dimensión. (Abajo.) ¿Tiene sentido la regresión lineal para hacer clasificación binaria? [Fuente: Original de A. Cuesta]

Función discriminante

- ▶ La regresión devuelve un valor continuo \hat{y} para un ejemplo x dado.
- ▶ Pero en clasificación buscamos una etiqueta \hat{t} , que es discreta.
- ▶ Con la **función discriminante** obtenemos \hat{t} a partir de \hat{y} .

Ej.:

$$\hat{t} = \begin{cases} \text{"etiqueta 0"} & \text{si } \hat{y} < \theta \\ \text{"etiqueta 1"} & \text{si } \hat{y} \geq \theta \end{cases}$$

- ▶ En el caso (muy concreto) de regresión lineal con ejemplos de una sola dimensión, como en la figura anterior:

$$\hat{y} = w_0 + w_1 x_1 = [w_0, w_1] \begin{bmatrix} 1 \\ x_1 \end{bmatrix} = \mathbf{w}^T \mathbf{x}$$

- ▶ θ es el umbral (*threshold*) con el que discriminamos.

Formulación del
problema de
optimización

Regresión lineal
Regresión logística
Notación
n-dimensional
Función de coste
Método de
optimización
Criterio de parada
Regularización

Ajuste fino de modelos

Medidas de bondad
Tabla de Confusión
Precision, Recall,
F-score
Curva ROC

Clasificación con Regresión Lineal

Clasificar es variar el umbral

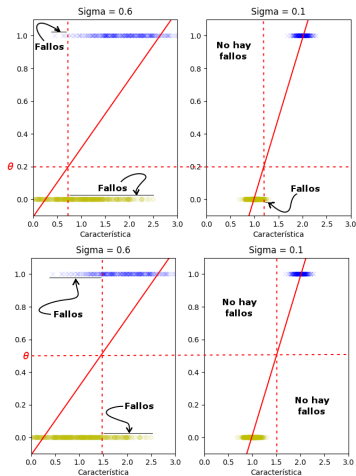


Figura: Variando el umbral logramos separar mejor las dos clases, aunque el conjunto con $\sigma = 0.6$ no es linealmente separable porque las dos clases se solapan. [Fuente: Original de A. Cuesta]

Formulación del
problema de
optimización

Regresión lineal
Regresión logística
Notación
n-dimensional
Función de coste
Método de
optimización
Criterio de parada
Regularización

Ajuste fino de modelos

Medidas de bondad
Tabla de Confusión
Precision, Recall,
F-score
Curva ROC

Regresión logística

Función sigmoide

- Transforma \hat{y} en una probabilidad \hat{p}

$$\hat{p} = S(\hat{y}) = S(\mathbf{w}^T \mathbf{x}) = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x})}$$




Figura: Función sigmoide. [Fuente: Anónimo @ Internet]

Función discriminante

$$\hat{t} = \begin{cases} \text{"etiqueta 0"} & \text{si } \hat{p} < \theta \\ \text{"etiqueta 1"} & \text{si } \hat{p} \geq \theta. \end{cases}$$

Cuadro: Tabla resumen de clasificación mediante regresión.

Reg. Lineal	Reg. Logística
<p>Conjunto de m ejemplos n dimensionales etiquetados</p> $\mathbf{w} = [w_0, w_1, w_2, \dots, w_n]^T$ $\mathbf{x}^{(i)} = [1, x_1^{(i)}, x_2^{(i)}, \dots, x_n^{(i)}]^T$ $\mathbf{X} = \begin{bmatrix} \mathbf{x}^{(1)T} \\ \vdots \\ \mathbf{x}^{(m)T} \end{bmatrix} = \begin{bmatrix} 1, & x_1^{(1)}, & x_2^{(1)}, & \dots & x_n^{(1)} \\ 1, & x_1^{(2)}, & x_2^{(2)}, & \dots & x_n^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1, & x_1^{(m)}, & x_2^{(m)}, & \dots & x_n^{(m)} \end{bmatrix}$ <div> $\hat{y}^{(i)} = \mathbf{w}^T \mathbf{x}^{(i)}$ $\hat{p}^{(i)} = 1/(1 + \exp(-\mathbf{w}^T \mathbf{x}^{(i)}))$ </div> $\hat{t}^{(i)} = \begin{cases} \text{"etiqueta 0"} & \text{si } \hat{y} < \theta \\ \text{"etiqueta 1"} & \text{si } \hat{y} \geq \theta \end{cases}$ $\hat{t}^{(i)} = \begin{cases} \text{"etiqueta 0"} & \text{si } \hat{p}^{(i)} < \theta \\ \text{"etiqueta 1"} & \text{si } \hat{p}^{(i)} \geq \theta \end{cases}$	

Formulación del
problema de
optimización

Regresión lineal
Regresión logística

Notación
n-dimensional

Función de coste

Método de
optimización

Criterio de parada

Regularización

Ajuste fino de modelos

Medidas de bondad

Tabla de Confusión

Precision, Recall,
F-score

Curva ROC

Búsqueda del mejor

- ▶ **Datos** : \mathbf{X} y \mathbf{t}
- ▶ **Modelo** : Lineal
- ▶ **Parámetros** : Aquella combinación **mejor** para los datos dados
- ▶ Hace falta **medir** = una **función de coste**

$$J(\mathbf{w}; \mathbf{X}, \mathbf{t})$$

⇒ El **mejor** = el argumento que la **minimiza**

$$\mathbf{w}^* = \arg \min_w (J(\mathbf{w}; \mathbf{X}, \mathbf{t})) .$$

- ▶ Funciones de coste típicas de regresión lineal:
MSE, MAE, RMSE
- ▶ Funciones de coste típicas de regresión logística:
La función *log-loss*.

Formulación del
problema de
optimización
Regresión lineal
Regresión logística
Notación
n-dimensional
Función de coste
Método de
optimización
Criterio de parada
Regularización
Ajuste fino de modelos
Medidas de bondad
Tabla de Confusión
Precision, Recall,
F-score
Curva ROC

Fórmula cerrada

- ▶ En el caso de la regresión lineal (y alguno más) se puede obtener una fórmula cerrada para calcular \mathbf{w}^*
- ▶ Es tan sencillo como resolver el siguiente sistema lineal:

$$\begin{bmatrix} 1, & x_1^{(1)}, & x_2^{(1)}, & \dots & x_n^{(1)} \\ 1, & x_1^{(2)}, & x_2^{(2)}, & \dots & x_n^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1, & x_1^{(m)}, & x_2^{(m)}, & \dots & x_n^{(m)} \end{bmatrix} \begin{bmatrix} w_0^* \\ w_1^* \\ w_2^* \\ \vdots \\ w_n^* \end{bmatrix} = \begin{bmatrix} t^{(1)} \\ t^{(2)} \\ \vdots \\ t^{(m)} \end{bmatrix};$$

Es decir $\mathbf{X}\mathbf{w}^* = \mathbf{t}$

Despejando \mathbf{w}^* tenemos que:

$$\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{t}$$

- ▶ Otro modo es resolver:

$$\frac{\partial J(\mathbf{w}, \mathbf{X}, \mathbf{t})}{\partial w_j} = 0, \quad \text{con } j = 1, 2, \dots, n.$$

Pero es preferible acudir a una solución numérica

Formulación del
problema de
optimización
Regresión lineal
Regresión logística
Notación
n-dimensional
Función de coste
Método de
optimización
Criterio de parada
Regularización
Ajuste fino de modelos
Medidas de bondad
Tabla de Confusión
Precision, Recall,
F-score
Curva ROC

Descenso del gradiente

- ▶ Se alcanza \mathbf{w}^* mediante aproximaciones sucesivas.
- ▶ Parece lógico intentar llegar por el *camino más corto*.
- ▶ Es decir, el que baja más rápido.
- ▶ La dirección de mayor descenso es $-\nabla J$.
- ▶ **Regla de actualización de pesos**

$$\mathbf{w}' = \mathbf{w} - \eta \nabla J(\mathbf{w})$$

donde

- ▶ \mathbf{w}' es el nuevo vector de pesos
- ▶ \mathbf{w} es el vector de pesos del que partimos
- ▶ η es el paso (ratio) de aprendizaje

Formulación del
problema de
optimización
Regresión lineal
Regresión logística
Notación
n-dimensional
Función de coste
Método de
optimización
Criterio de parada
Regularización
Ajuste fino de modelos
Medidas de bondad
Tabla de Confusión
Precision, Recall,
F-score
Curva ROC

Descenso del gradiente

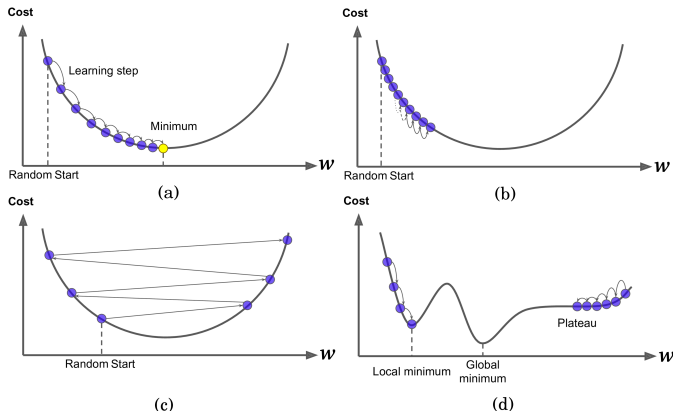


Figura: Efecto del ratio de aprendizaje η en el descenso del gradiente para $f(x)$. (a) Con un buen ratio, (b) con un ratio demasiado pequeño, (c) con uno demasiado grande, y (d) cuando J tiene varios mínimos locales y mesetas (*plateau*).

Formulación del
problema de
optimización
Regresión lineal
Regresión logística
Notación
 n -dimensional
Función de coste
Método de
optimización
Criterio de parada
Regularización
Ajuste fino de modelos
Medidas de bondad
Tabla de Confusión
Precision, Recall,
F-score
Curva ROC

Criterio de parada

- ▶ Límite en el número de iteraciones
- ▶ Convergencia a un vector de pesos
- ▶ *Early Stopping*




Figura: Utilización del conjunto de validación para decidir cuando debemos parar de aprender.

Añadir un término en la función de coste para penalizar los pesos

- ▶ Ridge

$$J_R(\mathbf{w}; \mathbf{X}, \mathbf{t}) = J(\mathbf{w}; \mathbf{X}, \mathbf{t}) + \frac{\alpha}{2} \sum_{j=1}^n w_j^2, \quad \text{con } \alpha \geq 0.$$

- ▶ Lasso

$$J_L(\mathbf{w}; \mathbf{X}, \mathbf{t}) = J(\mathbf{w}; \mathbf{X}, \mathbf{t}) + \alpha \sum_{j=1}^n |w_j|, \quad \text{con } \alpha \geq 0.$$

- ▶ Elastic Net

$$J_{\text{EN}}(\mathbf{w}; \mathbf{X}, \mathbf{t}) = J(\mathbf{w}; \mathbf{X}, \mathbf{t}) + (r)J_{\text{L}}(\mathbf{w}; \mathbf{X}, \mathbf{t}) + (1 - r)J_{\text{R}}(\mathbf{w}; \mathbf{X}, \mathbf{t}),$$

$$\text{con } 0 \leq r \leq 1.$$




Figura: Descenso del gradiente en 2 dims. con regularización *Ridge* y *Lasso*

Formulación del problema de optimización

- Regresión lineal
- Regresión logística
- Notación n-dimensional
- Función de coste
- Método de optimización
- Criterio de parada
- Regularización

- Formulación del problema de optimización
- Regresión lineal
- Regresión logística
- Notación n-dimensional
- Función de coste
- Método de optimización
- Criterio de parada
- Regularización

Ajuste fino de modelos

Ajuste fino de modelos

Medidas de bondad

- Tabla de Confusión
- Precision, Recall, F-score
- Curva ROC

- Medidas de bondad
- Tabla de Confusión
- Precision, Recall, F-score
- Curva ROC

Parámetros vs. Hiperparámetros

- ▶ Los hiperparámetros configuran el proceso de aprendizaje
- ▶ Los parámetros pertenecen al modelo

Métodos de búsqueda

- ▶ Ordenada (*grid*)
- ▶ Aleatoria
- ▶ Heurística
- ▶ Métodos de ensamblado (combinación de clasificadores)

Formulación del
problema de
optimización
Regresión lineal
Regresión logística
Notación
n-dimensional
Función de coste
Método de
optimización
Criterio de parada
Regularización

Ajuste fino de modelos

Medidas de bondad
Tabla de Confusión
Precision, Recall,
F-score
Curva ROC

Formulación del problema de optimización

- Regresión lineal
- Regresión logística
- Notación n-dimensional
- Función de coste
- Método de optimización
- Criterio de parada
- Regularización

Formulación del
problema de
optimización

- Regresión lineal
- Regresión logística
- Notación
n-dimensional
- Función de coste
- Método de
optimización
- Criterio de parada
- Regularización

Ajuste fino de modelos

Ajuste fino de modelos

Medidas de bondad

- Tabla de Confusión
- Precision, Recall,
F-score
- Curva ROC

Medidas de bondad

- Tabla de Confusión
- Precision, Recall, F-score
- Curva ROC

Tabla de Confusión

		Condition (as determined by "Gold standard")			
Total population		Condition positive	Condition negative	Prevalence = $\frac{\Sigma \text{ Condition positive}}{\Sigma \text{ Total population}}$	
Test outcome	Test outcome positive	True positive	False positive (Type I error)	Positive predictive value (PPV, Precision) = $\frac{\Sigma \text{ True positive}}{\Sigma \text{ Test outcome positive}}$	False discovery rate (FDR) = $\frac{\Sigma \text{ False positive}}{\Sigma \text{ Test outcome positive}}$
	Test outcome negative	False negative (Type II error)	True negative	False omission rate (FOR) = $\frac{\Sigma \text{ False negative}}{\Sigma \text{ Test outcome negative}}$	Negative predictive value (NPV) = $\frac{\Sigma \text{ True negative}}{\Sigma \text{ Test outcome negative}}$
	Positive likelihood ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$	True positive rate (TPR, Sensitivity, Recall) = $\frac{\Sigma \text{ True positive}}{\Sigma \text{ Condition positive}}$	False positive rate (FPR, Fall-out) = $\frac{\Sigma \text{ False positive}}{\Sigma \text{ Condition negative}}$	Accuracy (ACC) = $\frac{\Sigma \text{ True positive} + \Sigma \text{ True negative}}{\Sigma \text{ Total population}}$	
	Negative likelihood ratio (LR-) = $\frac{\text{FNR}}{\text{TNR}}$	False negative rate (FNR) = $\frac{\Sigma \text{ False negative}}{\Sigma \text{ Condition positive}}$	True negative rate (TNR, Specificity, SPC) = $\frac{\Sigma \text{ True negative}}{\Sigma \text{ Condition negative}}$		
	Diagnostic odds ratio (DOR) = $\frac{\text{LR+}}{\text{LR-}}$				

- Formulación del problema de optimización
 - Regresión lineal
 - Regresión logística
- Notación n-dimensional
- Función de coste
- Método de optimización
- Criterio de parada
- Regularización
- Ajuste fino de modelos

Medidas de bondad

Tabla de Confusión

Figura: Tabla de confusión en clasificación binaria y medidas derivadas.

[Fuente: Wikipedia]

Precision

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall

$$\text{Recall} = \frac{TP}{TP + FN}$$




Figura: Un clasificador puede lograr un *precision* o un *recall* del 100 %. Basta con que no haya ningún FP o ningún FN respectivamente. [Fuente: Original de A. Cuesta]

Compromiso Precision–Recall




Figura: Curvas de *precision* y *recall* para el conjunto de datos de la Figura 1 con $\sigma = 0,6$. [Fuente: Original de A. Cuesta]

F-score

$$\text{F-score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Formulación del
problema de
optimización
Regresión lineal
Regresión logística
Notación
n-dimensional
Función de coste
Método de
optimización
Criterio de parada
Regularización
Ajuste fino de modelos
Medidas de bondad
Tabla de Confusión
Precision, Recall,
F-score
Curva ROC

Curva ROC




Figura: Curvas ROC para el conjunto de datos de la Figura 1 con $\sigma = 0,6$.

[Fuente: Original de A. Cuesta]