

# Aproximación probabilística al RP

**Alfredo Cuesta Infante**

E. T. S. Ingeniería Informática  
Universidad Rey Juan Carlos

Master Univ. en Visión Artificial  
**Reconocimiento de Patrones**

## Probabilidad

- PMF, PDFs y CDFs
- Probabilidad Conjunta
- Teorema de Bayes

## Aproximación probabilística al ML

- Planteamiento

## Naive Bayes

- Modelo
- Aprendizaje e Inferencia

Probabilidad

- PMF, PDFs y CDFs
- Probabilidad Conjunta
- Teorema de Bayes

Aproximación  
probabilística al ML

- Planteamiento

Naive Bayes

- Modelo
- Aprendizaje e  
Inferencia

## Probabilidad

PMF, PDFs y CDFs  
Probabilidad Conjunta  
Teorema de Bayes

### Probabilidad

PMF, PDFs y CDFs  
Probabilidad Conjunta  
Teorema de Bayes

### Aproximación probabilística al ML Planteamiento

### Naive Bayes

Modelo  
Aprendizaje e  
Inferencia


## Aproximación probabilística al ML Planteamiento

## Naive Bayes

Modelo  
Aprendizaje e Inferencia

## Variables aleatorias

- ▶ Variables sobre las que tenemos una incertidumbre se denominan *variables aleatorias*, v.a.
- ▶ Pueden ser continuas o discretas.
- ▶ Sólo podemos decir de qué manera se distribuyen sus posibles valores, es decir qué probabilidad tienen.



## Distribución de probabilidad

- ▶ Función que modela:
  - ▶ la masa de probabilidad de una variable discreta
  - ▶ la densidad de probabilidad de una variable continua
  - ▶ la masa/densidad acumulada de una variable continua

PMF  
PDF  
CDF

Probabilidad

PMF, PDFs y CDFs  
Probabilidad Conjunta  
Teorema de Bayes

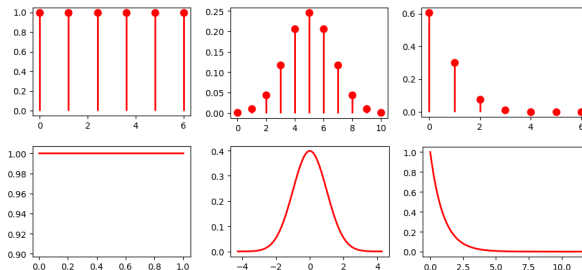
Aproximación  
probabilística al ML  
Planteamiento

Naive Bayes

Modelo

Aprendizaje e  
Inferencia

## Ejemplos de PMFs y PDFs



**Figura:** Arriba: PMF Uniforme, Binomial y Poisson. Abajo: PDF Uniforme, Normal o Gaussiana, Exponencial. [Fuente: Original de A. Cuesta]

Probabilidad

PMF, PDFs y CDFs  
Probabilidad Conjunta  
Teorema de Bayes

Aproximación  
probabilística al ML  
Planteamiento


Naive Bayes

Modelo  
Aprendizaje e  
Inferencia



## Probabilidad Conjunta

- ▶ Dos o más v.a. tendrán, en general, una distribución de probabilidad **conjunta**.



## Marginales

Sea la distribución conjunta de  $(x, y) = P(x, y)$

- ▶ Distribución marginal de  $x = P(x)$ 
  - v.a. discretas:  $P(x) = \sum_{y=-\infty}^{y=+\infty} P(x, y)$ .
  - v.a. continuas:  $P(x) = \int_{y=-\infty}^{y=+\infty} P(x, y)$ .
- ▶ Distribución marginal de  $y = P(y)$ 
  - *lo mismo que para  $x$*

Probabilidad

PMF, PDFs y CDFs

Probabilidad Conjunta

Teorema de Bayes

Aproximación  
probabilística al ML  
Planteamiento

Naive Bayes

Modelo

Aprendizaje e  
Inferencia

## Distribución condicionada

- Supongamos dos v.a. distribuidas conjuntamente.

Si conocemos el valor de una de ellas, entonces la incertidumbre la tenemos sólo sobre la otra.

*Ej. En  $p(x|y)$  hay incertidumbre sobre  $x$  pero no sobre  $y$ .*

- La distribución condicionada y la marginal de una v.a. son distribuciones univariadas, ¡pero son cosas muy diferentes!

## Regla de la cadena

Ej. 2 variables:

$$p(x, y) = p(x)p(y|x) = p(y)p(x|y) = p(x)p(y|x).$$

Ej. 4 variables:

$$p(x, y, z, w) = p(w)p(z|w)p(y|z, w)p(x|y, z, w),$$

o también:

$$p(x, y, z, w) = p(x, w)p(y, z|x, w) = p(y)p(x, z, w|y) = \dots$$

Probabilidad

PMF, PDFs y CDFs

Probabilidad Conjunta

Teorema de Bayes

Aproximación

probabilística al ML

Planteamiento

Naive Bayes

Modelo

Aprendizaje e  
Inferencia



## Independencia

- ▶ La distribución conjunta de dos v.a. independientes es la multiplicación de sus distribuciones individuales. En general

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i)$$

## Independencia condicional

- ▶ Cuando el conocimiento de una v.a. 'x' convierte a otras dos 'v' y 'w' en independientes, se dice que éstas son **condicionalmente independientes**.

$$p(v, w|x) = p(v|x)p(w|x)$$

Probabilidad

PMF, PDFs y CDFs

Probabilidad Conjunta

Teorema de Bayes

Aproximación  
probabilística al ML  
Planteamiento

Naive Bayes

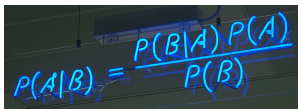
Modelo

Aprendizaje e  
Inferencia

# Teorema de Bayes

El teorema surge directamente de aplicar la regla de la cadena a la densidad conjunta.

$$\begin{cases} p(A, B) = p(B)p(A|B) & \text{y despejando } p(A|B) = p(A, B)/p(B) \\ p(A, B) = p(A)p(B|A) & \text{que introducimos arriba} \end{cases}$$


$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

## Likelihood

How probable is the evidence  
given that our hypothesis is true?

## Prior

How probable was our hypothesis  
before observing the evidence?

$$P(H | e) = \frac{P(e | H) P(H)}{P(e)}$$

## Posterior

How probable is our hypothesis  
given the observed evidence?  
(Not directly computable)

## Marginal

How probable is the new evidence  
under all possible hypotheses?  
 $P(e) = \sum P(e | H_i) P(H_i)$

## Probabilidad

PMF, PDFs y CDFs  
Probabilidad Conjunta  
Teorema de Bayes

## Aproximación probabilística al ML Planteamiento

## Naive Bayes

Modelo  
Aprendizaje e Inferencia

Probabilidad

PMF, PDFs y CDFs  
Probabilidad Conjunta  
Teorema de Bayes

Aproximación  
probabilística al ML  
Planteamiento

Naive Bayes

Modelo  
Aprendizaje e  
Inferencia

## Modelo

- PDF conjunta de los datos y las etiquetas  $p(\mathbf{X}, \mathbf{t}; \mathbf{w})$ , que dependerá del vector de parámetros  $\mathbf{w}$ .

## Aprendizaje

- Los parámetros serán **óptimos** cuando la probabilidad conjunta de los datos y las etiquetas sea máxima.

$$\mathbf{w}^* = \arg \max_{\mathbf{w}} p(\mathbf{X}, \mathbf{t}; \mathbf{w})$$

## Inferencia

- La etiqueta estimada para un nuevo ejemplo  $\mathbf{z}$  es:

$$\hat{t} = \arg \max_t p(t|\mathbf{z}).$$

Aplicando el teorema de Bayes:

$$\hat{t} = \arg \max_t \left( \frac{p(t)p(\mathbf{z}|t)}{p(\mathbf{z})} \right) = \arg \max_t (p(t)p(\mathbf{z}|t)).$$

Probabilidad

PMF, PDFs y CDFs  
Probabilidad Conjunta  
Teorema de Bayes

Aproximación  
probabilística al ML  
Planteamiento

Naive Bayes

Modelo  
Aprendizaje e  
Inferencia

## Probabilidad

PMF, PDFs y CDFs  
Probabilidad Conjunta  
Teorema de Bayes

Probabilidad

PMF, PDFs y CDFs  
Probabilidad Conjunta  
Teorema de Bayes

Aproximación  
probabilística al ML  
Planteamiento

Naive Bayes

Modelo  
Aprendizaje e  
Inferencia

## Aproximación probabilística al ML

Planteamiento

## Naive Bayes

Modelo  
Aprendizaje e Inferencia

## Modelo

- Asumir 2 condiciones para simplificar la construcción de  $p(\mathbf{X}, \mathbf{t}; \mathbf{w})$ :

1. El conjunto de datos es iid  
(independiente y está idénticamente distribuido)

$$p(\mathbf{X}, \mathbf{t}) = \prod_{i=1}^m p(\mathbf{x}^{(i)}, t_i), \text{ y también } p(\mathbf{X}|\mathbf{t}) = \prod_{i=1}^m p(\mathbf{x}^{(i)}|t_i)$$

2. Las características son condicionalmente independientes  
dada la etiqueta.

$$p(\mathbf{x}|\mathbf{t}) = \prod_{j=1}^n p(x_j|\mathbf{t}).$$

Por tanto:

$$\begin{aligned} p(\mathbf{X}, \mathbf{t}) &= p(\mathbf{t})p(\mathbf{X}|\mathbf{t}) = \prod_{i=1}^m p(t_i)p(\mathbf{x}^{(i)}|t_i) \\ &= \prod_{i=1}^m p(t_i) \prod_{j=1}^n p(x_j^{(i)}|t_i). \end{aligned}$$

Probabilidad

PMF, PDFs y CDFs  
Probabilidad Conjunta  
Teorema de BayesAproximación  
probabilística al ML  
Planteamiento

Naive Bayes

Modelo

Aprendizaje e  
Inferencia



## Inferencia

- ▶ Aplicando la suposición 2:

$$\hat{t} = \arg \max_t \left( p(t) \prod_{i=1}^n p(z_i|t) \right)$$

- ▶ Añadir el logaritmo a la función que queremos optimizar para convertir productos en sumas:

$$\hat{t} = \arg \max_t \left( \log p(t) + \sum_{i=1}^n \log p(z_i|t) \right) \quad (2)$$

- ▶ Los parámetros de las distribuciones a priori y de verosimilitud han sido aprendidos previamente.

Vamos a ver dos ejemplos concretos de clasificador Naive Bayes (NBC):

- ▶ Para características continuas *NBC Gaussiano*
- ▶ Para características discretas *NBC Multinomial*

Probabilidad

PMF, PDFs y CDFs

Probabilidad Conjunta

Teorema de Bayes

Aproximación

probabilística al ML


Planteamiento

Naive Bayes

Modelo

Aprendizaje e  
Inferencia





## Probabilidad

- PMF, PDFs y CDFs
- Probabilidad Conjunta
- Teorema de Bayes

## Aproximación probabilística al ML

## Naive Bayes

## Modelo Aprendizaje e Inferencia

