

Modelos Gaussianos

Alfredo Cuesta Infante

E. T. S. Ingeniería Informática
Universidad Rey Juan Carlos

Master Univ. en Visión Artificial
Reconocimiento de Patrones

La distribución Normal

PDF

Media y Covarianza

Curvas de equidensidad

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidad

Análisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización

Análisis de Discriminantes Gaussianos

Mezclas de Gaussianas

Esperanza-Maximización

La distribución Normal

PDF

Media y Covarianza

Curvas de equidensidad

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidad

Análisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización

Análisis de Discriminantes Gaussianos

Mezclas de Gaussianas

Esperanza-Maximización

Distribución Normal

$$\mathcal{N}(x) = \frac{\exp\left(-\frac{(x-\mu)^2}{\sigma^2}\right)}{\sqrt{2\pi\sigma^2}}$$

- ▶ Tiene 2 parámetros: la media y la varianza
- ▶ x tiene 1 sola dimensión
- ▶ La media μ es un escalar
- ▶ La varianza σ^2 es un escalar positivo
- ▶ $\sqrt{(x-\mu)^2}$ es la distancia Euclídea (en 1 dim.) desde x a la media μ

Distribución MVN

$$\text{MVN}(\mathbf{x}) = \frac{\exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)}{\sqrt{(2\pi)^n |\boldsymbol{\Sigma}|}}$$

- ▶ Tiene 2 parámetros: la media y la covarianza
- ▶ \mathbf{x} es un vector n -dimensional
- ▶ La media $\boldsymbol{\mu}$ es un vector n -dimensional
- ▶ La matriz de covarianza $\boldsymbol{\Sigma}$ es una matriz definida positiva de tamaño $n \times n$
- ▶ $\sqrt{((\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}))}$ es la distancia Mahalanobis desde \mathbf{x} a la media $\boldsymbol{\mu}$

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización

La distribución Normal o Gaussiana

La media

El estimador MLE para la MVN es el *clásico* promedio para cada componente.


$$\boldsymbol{\mu} = (\mu_1, \dots, \mu_n), \text{ donde } \mu_j = \mathbb{E}[\mathbf{x}_j] = \frac{1}{m} \sum_{i=1}^m x_j^{(i)}, \text{ para } j = 1, \dots, n.$$

La covarianza

Es una matriz (definida positiva) cuyos elementos expresan la varianza de un componente respecto de otro. Su estimador MLE es:

$$\Sigma_{ij} = \mathbb{E}[(\mathbf{x}_i - \mu_i)(\mathbf{x}_j - \mu_j)].$$

- ▶ Σ diagonal \Rightarrow componentes independientes
- ▶ En otro caso hay dependencia lineal (correlación) entre componentes



$$\Sigma = \begin{bmatrix} 3 & 0 \\ 0 & 15 \end{bmatrix} \text{ vs. } \Sigma = \begin{bmatrix} 3 & -5 \\ -5 & 15 \end{bmatrix}$$

- Descomponer de la matriz de covarianza en autovalores y autovectores, y después tomar su inversa

$$\Sigma^{-1} = \mathbf{U}\Lambda^{-1}\mathbf{U}^T = \sum_{i=1}^n \frac{1}{\lambda_i} \mathbf{u}_i \mathbf{u}_i^T$$

- Reescribir la distancia Mahalanobis con esta expresión de Σ^{-1} :


$$\begin{aligned} d_M(\mathbf{x}) &= (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) = (\mathbf{x} - \boldsymbol{\mu})^T \left(\sum_{i=1}^n \frac{1}{\lambda_i} \mathbf{u}_i \mathbf{u}_i^T \right) (\mathbf{x} - \boldsymbol{\mu}) \\ &= \sum_{i=1}^n \frac{1}{\lambda_i} (\mathbf{x} - \boldsymbol{\mu})^T \mathbf{u}_i \mathbf{u}_i^T (\mathbf{x} - \boldsymbol{\mu}) \end{aligned}$$

- Sea $y_i = (\mathbf{x} - \boldsymbol{\mu})^T \mathbf{u}_i$. La distancia Mahalanobis es finalmente:

$$d_M(\mathbf{x}) = \sum_{i=1}^n \frac{y_i^2}{\lambda_i}$$

- Si fijamos esta distancia a un valor concreto D , entonces $D = \sum_{i=1}^n y_i^2 / \lambda_i$ es la expresión una **elipse** centrada en $\boldsymbol{\mu}$, cuyo eje i -ésimo tiene la dirección \mathbf{u}_i y tamaño $\sqrt{\lambda_i}$

Curvas de equidensidad



La distribución Normal

PDF

Media y Covarianza

Curvas de equidensidad

Análisis de Discriminantes Gaussianos

Mezclas de Gaussianas

Esperanza-Maximización

Alfredo Cuesta
Infante

La distribución Normal
PDF

Media y Covarianza
Curvas de
equidensidad

Análisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas
Esperanza-
Maximización

- Asumiendo que el subconjunto de ejemplos con etiqueta t está distribuido según una MVN(μ_t, Σ_t), el modelo de verosimilitud es:

$$p(\mathbf{X}|t) = \text{MVN}(\mathbf{X}|t; \mu_t, \Sigma_t)$$

- La etiqueta estimada MAP es:

$$\hat{t} = \arg \max_t (\log p(t) + \log \text{MVN}(\mathbf{X}|t; \mu_t, \Sigma_t)), \text{ para cada } \mathbf{x}.$$

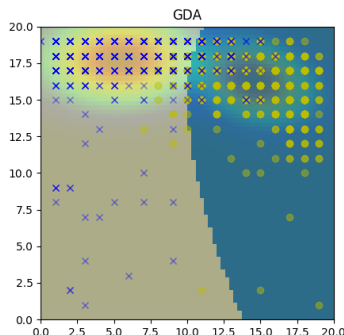


Figura: Superficie de decisión y densidades de las MVN para un GDA con el conjunto de datos '0' vs. '1'. [Fuente: Original de A. Cuesta]

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos



Mezclas de Gaussianas

Esperanza-
Maximización

- Equivalente a minimizar la distancia Mahalanobis de un punto \mathbf{x} al centro de cada una de las MVN que modelan las diferentes clases;

$$\hat{t} = \arg \min_t \left((\mathbf{x} - \boldsymbol{\mu}_t)^T \boldsymbol{\Sigma}_t^{-1} (\mathbf{x} - \boldsymbol{\mu}_t) \right), \text{ para cada } \mathbf{x}.$$

- Cuando la matriz de covarianza es diagonal, entonces recuperamos el **NBC Gaussiano**. En caso contrario:
 - Si cada subconjunto de datos con la misma etiqueta tiene covarianzas diferentes tenemos **Discriminantes Cuadráticos** (QD)
 - Si todas son iguales tenemos **Discriminantes Lineales** (LD)



La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización

¿Podemos averiguar la ec. de la superficie de decisión?

- Para dos clases $t = \{0, 1\}$, la distribución a posteriori de un nuevo ejemplo \mathbf{z} es:

$$p(t = 0|\mathbf{z}) \propto p(t = 0) \cdot (2\pi|\mathbf{\Sigma}_0|)^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\mathbf{z} - \boldsymbol{\mu}_0)^T \mathbf{\Sigma}_0^{-1}(\mathbf{z} - \boldsymbol{\mu}_0)\right)$$

$$p(t = 1|\mathbf{z}) \propto p(t = 1) \cdot (2\pi|\mathbf{\Sigma}_1|)^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\mathbf{z} - \boldsymbol{\mu}_1)^T \mathbf{\Sigma}_1^{-1}(\mathbf{z} - \boldsymbol{\mu}_1)\right)$$

- El log. de su cociente es:

$$\delta = \log \frac{p(t = 0|\mathbf{z})}{p(t = 1|\mathbf{z})} = \log p(t = 0|\mathbf{z}) - \log p(t = 1|\mathbf{z}),$$

- Manipulando se llega a

$$\begin{aligned} \delta = & \log p(t = 0) - \frac{1}{2} \log |\mathbf{\Sigma}_0| - \frac{1}{2}(\mathbf{z} - \boldsymbol{\mu}_0)^T \mathbf{\Sigma}_0^{-1}(\mathbf{z} - \boldsymbol{\mu}_0) \\ & - \log p(t = 1) + \frac{1}{2} \log |\mathbf{\Sigma}_1| + \frac{1}{2}(\mathbf{z} - \boldsymbol{\mu}_1)^T \mathbf{\Sigma}_1^{-1}(\mathbf{z} - \boldsymbol{\mu}_1). \end{aligned}$$

☺ La superficie de decisión será el conjunto de puntos \mathbf{z} donde $\delta = 0$.

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas


Esperanza-
Maximización

¿Podemos averiguar la ec. de la superficie de decisión?

- ▶ Dejando a un lado de la igualdad todo lo que depende de \mathbf{z} se obtiene la siguiente forma cuadrática:

$$(\mathbf{z} - \boldsymbol{\mu}_1)^T \boldsymbol{\Sigma}_1^{-1} (\mathbf{z} - \boldsymbol{\mu}_1) - (\mathbf{z} - \boldsymbol{\mu}_0)^T \boldsymbol{\Sigma}_0^{-1} (\mathbf{z} - \boldsymbol{\mu}_0) = C,$$

donde $C = 2 \log p(t=1) - 2 \log p(t=0) + \log |\boldsymbol{\Sigma}_1| - \log |\boldsymbol{\Sigma}_0|$ es un valor constante dadas las matrices de covarianza de cada clase y la distribución a priori.



- ▶ obtenemos una manera directa de clasificar nuevos ejemplos según la distancia Mahalanobis de estos al centro de cada clase:

$$\hat{t} = \begin{cases} 0 & \text{si } d_{M1}^2(\mathbf{z}) - d_{M0}^2(\mathbf{z}) + C < 0 \\ 1 & \text{si } d_{M1}^2(\mathbf{z}) - d_{M0}^2(\mathbf{z}) + C > 0 \end{cases}$$

⇒ **Discriminante Gaussiano Cuadrático (QD)**

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos


Mezclas de Gaussianas

Esperanza-
Maximización

¿Podemos averiguar la ec. de la superficie de decisión?


- Si $\Sigma_0 = \Sigma_1 = \Sigma$, entonces

$$(z - \mu_1)^T \Sigma^{-1} (z - \mu_1) - (z - \mu_0)^T \Sigma^{-1} (z - \mu_0) = C.$$



- Llegamos a una expresión lineal en z

$$-z^T \Sigma^{-1} \mu_1 - \mu_1^T \Sigma^{-1} z + z^T \Sigma^{-1} \mu_0 + \mu_0^T \Sigma^{-1} z = C.$$



- se puede construir, un discriminante similar al del QDA pero lineal
⇒ **Discriminante Gaussiano Lineal (LD)**

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización

La distribución Normal

PDF

Media y Covarianza

Curvas de equidensidad

Análisis de Discriminantes Gaussianos

Mezclas de Gaussianas

Esperanza-Maximización

Alfredo Cuesta
Infante

La distribución Normal

PDF

Media y Covarianza


Curvas de
equidensidad

Análisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización

¿Y si mis datos se *concentran* en **dos** puntos?



- Podemos utilizar **dos** MVNs, una para cada concentración, ¡¡ pero la PDF tiene que ser **válida** !!

Ej. $PDF(\mathbf{x}) = 30\% \cdot MVN_1(\mathbf{x}) + 70\% \cdot MVN_2(\mathbf{x})$

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización

GMM

$$p(\mathbf{x}) = \sum_{i=1}^K \pi_i \cdot \text{MVN}(\mathbf{x}; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i), \text{ sujeto a } \sum_{i=1}^K \pi_i = 1.$$

Clasificación

- El GMM es la verosimilitud $p(\mathbf{x}|t)$

Agrupamiento

- Un GMM de K MVNs da lugar a K grupos
- El grupo i -ésimo tendrá como centroide la media $\boldsymbol{\mu}_i$.
- Aplicación en compresión de imágenes o la cuantización de colores



La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización

Algoritmo EM

- ▶ Parámetros del modelo:
 - ▶ la media y la covarianza de cada MVN que forma la mezcla,
 - ▶ el peso que cada MVN tiene en la mezcla,
 - ▶ para cada una de las etiquetas diferentes que hay.
- ▶ Datos: Conjunto de ejemplos etiquetados 0 ó 1

x_1	x_2	t		x_1	x_2	t		x_1	x_2	t
2.36	0.31	0		2.36	0.31	0		1.73	1.53	0
4.49	-1.42	0		4.49	-1.42	0		0.22	1.39	0
1.12	2.13	0		1.12	2.13	0		1.09	2.62	0
1.23	-0.42	1		1.98	1.36	0		-1.67	2.14	0
-0.66	-1.64	1		0.62	0.76	0		1.52	1.02	0
1.98	1.36	0		4.17	-1.03	0		0.53	4.39	0
2.01	2.97	1		1.24	1.35	0		2.03	-0.53	0
0.62	0.76	0		1.86	3.41	0		3.13	1.32	0
4.17	-1.03	0		0.61	-0.37	0		3.06	-1.30	0
2.60	1.89	1		0.83	0.61	0		2.52	1.42	0
3.50	0.86	1		2.02	-0.96	0		1.48	1.46	0
1.24	1.35	0		1.13	1.10	0		2.16	1.90	0
2.57	0.88	1		1.72	1.53	0		1.11	0.40	0
1.86	3.41	0		0.90	0.00	0		2.64	-1.01	0
2.77	3.11	1		2.06	1.52	0		2.92	-2.73	0
-0.15	-1.29	1		0.28	2.70	0		3.50	0.16	0
0.67	-0.64	1		1.23	-0.42	1				
0.61	-0.37	0		-0.66	-1.64	1		x_1	x_2	t
0.83	0.61	0		2.01	2.97	1		1.14	-0.49	1
2.02	-0.96	0		2.60	1.89	1		0.82	-1.39	1
1.13	1.10	0		3.50	0.86	1		2.96	-0.99	1
1.72	1.53	0		2.57	0.88	1		3.39	0.41	1
3.11	3.05	1		2.77	3.11	1		2.42	0.46	1
3.10	2.67	1		-0.15	-1.29	1		2.02	1.53	1
3.28	1.63	1		0.67	-0.64	1		2.22	2.19	1
3.10	1.06	1		3.11	3.05	1		1.85	0.27	1
0.90	0.00	0		3.10	2.67	1		0.49	0.83	1
2.06	1.52	0		3.28	1.63	1		3.17	1.98	1
1.54	-0.14	1		3.10	1.06	1		3.48	1.58	1
0.28	2.70	0		1.54	-0.14	1		4.41	2.69	1
								4.07	1.69	1
								2.23	0.87	1

Sea el **factor de pertenencia** de un ejemplo \mathbf{x} a la k -ésima MVN:

$$w_k = \frac{\pi_k \cdot \text{MVN}_k(\mathbf{x})}{\sum_{i=1}^K \pi_k \cdot \text{MVN}_k(\mathbf{x})},$$

Paso E

- ▶ Calcular el factor de pertenencia de cada uno de los ejemplos
- ▶ Obtenemos una tabla de valores $W = \{w_{i,k}\}$ para $i = 1 \dots M$, $k = 1 \dots K$; donde M es el número de ejemplos y cada fila suma 1.

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización

Paso M

- ▶ Comenzamos calculando $M_k = \sum_{i=1}^M w_{i,k}$, es decir la suma de la k -ésima columna de la tabla W , para $k = 1 \dots K$.
- ▶ A continuación actualizamos los K pesos con la regla:

$$\pi_k^{\text{next}} = M_k / M$$

- ▶ Actualizamos la media y covarianza de cada MVN_k .

$$\mu_k^{\text{next}} = \frac{1}{M_k} \sum_{i=1}^M (w_{i,k} \mathbf{x}^{(i)})$$

$$\Sigma_k^{\text{next}} = \frac{1}{M_k} \sum_{i=1}^M (w_{i,k} (\mathbf{x}^{(i)} - \mu_k^{\text{next}})(\mathbf{x}^{(i)} - \mu_k^{\text{next}})^T)$$

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización

Arranque

- Dar unos valores iniciales a

$$\{\pi_1, \dots, \pi_K, \mu_1, \dots, \mu_K, \Sigma_1, \dots, \Sigma_K\}$$

Por ej.

$$\pi_1 = \dots = \pi_K = 1/K$$

Por cada MNV, calcular μ y Σ de un subconjunto de puntos aleatorio.




Figura: Cuatro GMMs con diferente número de MVN componentes para el conjunto de datos '0' vs. '1'. [Fuente: Original de A. Cuesta]

La distribución Normal

PDF

Media y Covarianza

Curvas de
equidensidadAnálisis de
Discriminantes
Gaussianos

Mezclas de Gaussianas

Esperanza-
Maximización