Combinación de Clasificadores (Ensembles)

Alfredo Cuesta Infante

E. T. S. Ingeniería Informática
Universidad Rey Juan Carlos

Master Univ. en Visión Artificial
Reconocimiento de Patrones

Contenidos

Contenidos

Combinación mediante votación

Votación *hard* vs. *soft*

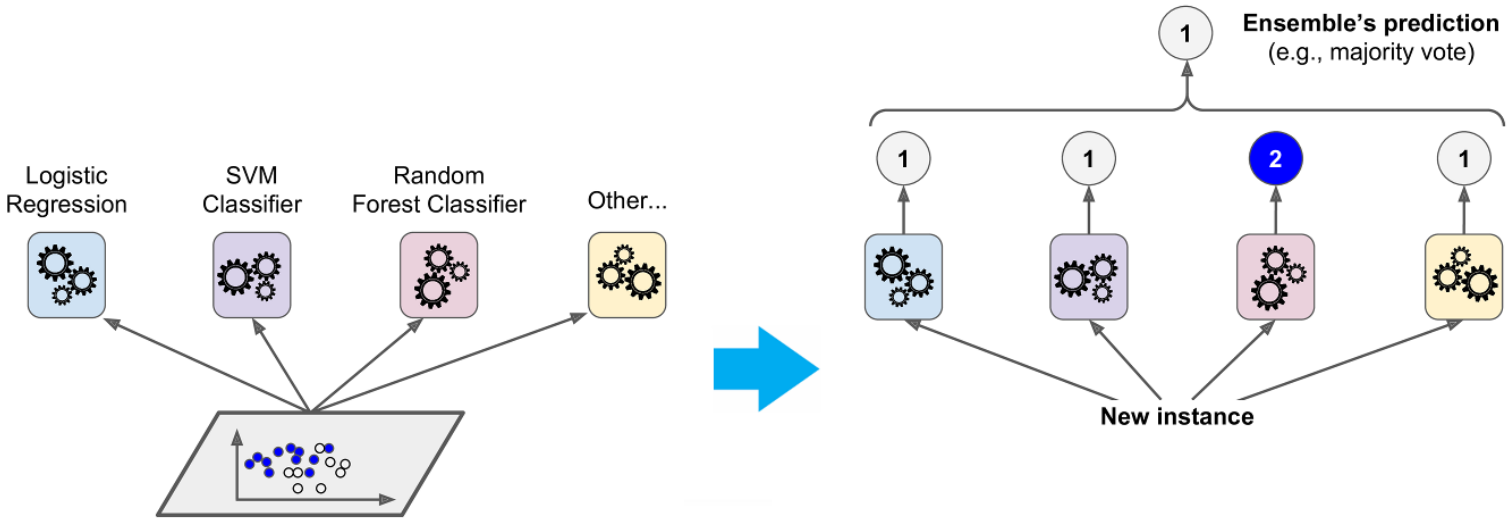

Figura: Combinación mediante votación

Cuadro: Ejemplo de votación *hard* vs. *soft*

	$p(t=0)$	$p(t=1)$
C_1	0.37	0.63
C_2	0.87	0.13
C_3	0.27	0.73
Votos	1	**2**
$\frac{1}{3}\sum_i p_i(t)$	**0.503**	0.496

Combinación mediante votación

Ejemplo

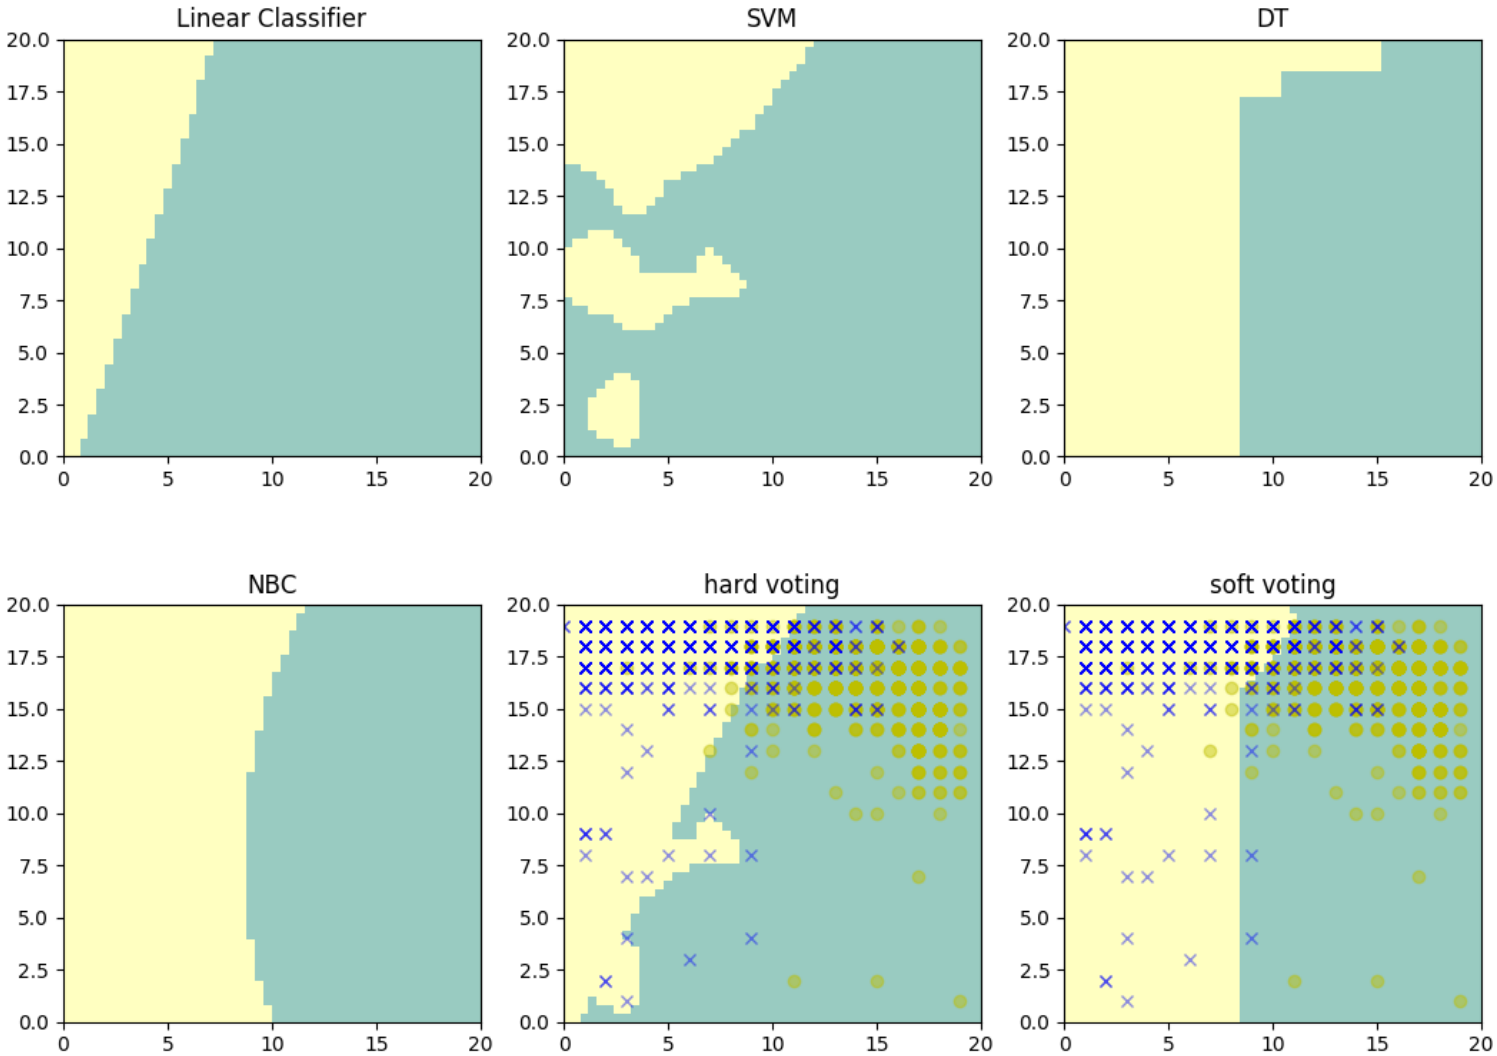

Contenidos

Bagging

- **b agg ing** = *bootstrap* + *aggregation*.
  - bootstrap es, en estadística, a remuestrear con remplazo
  - *aggregation* es el proceso de combinar datos de diferentes fuentes
- NO combina varios clasificadores,

  SÍ el resultado de un clasificador sobre diferentes subconjuntos

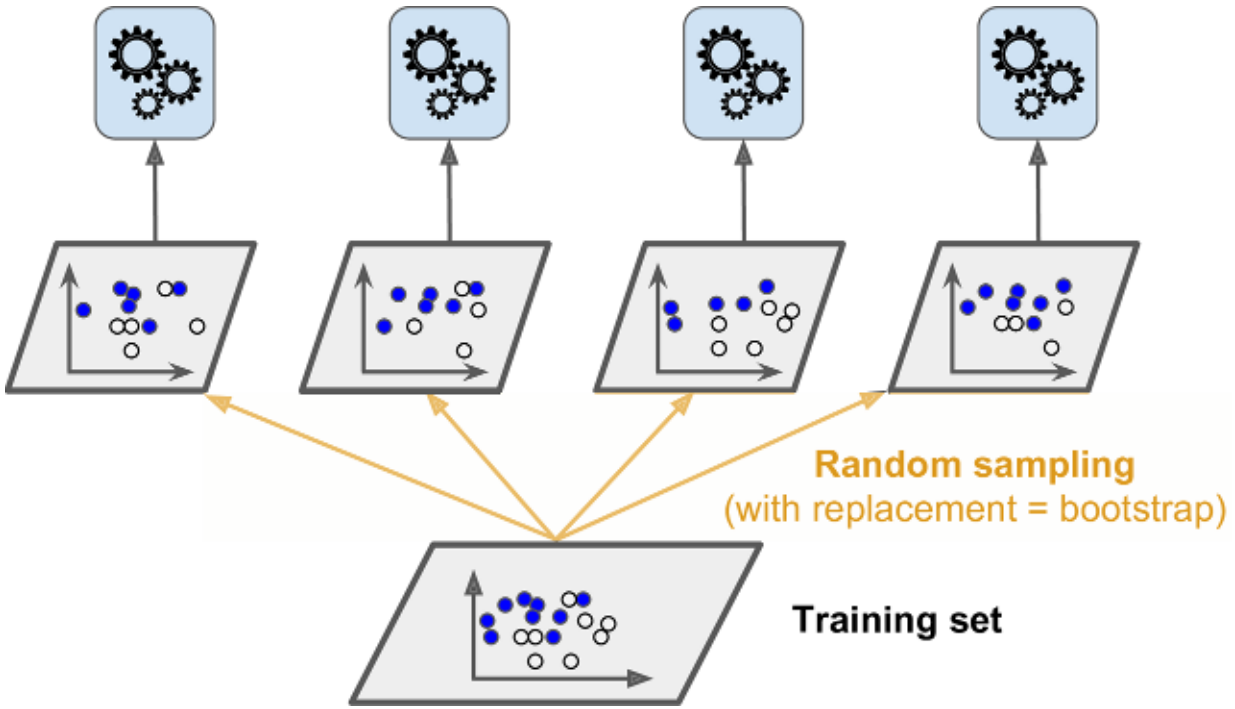

Figura: Bagging

Bagging

Bagging vs. Pasting

- **Bagging.**
  - A partir del conjunto de entrenamiento se crean K subconjuntos
  - formados por N ejemplos aleatorios.
  - Con remplazo = cada ejemplo puede ser seleccionado más de una vez durante el proceso de creación.
  - Después se aprende un clasificador con cada uno de ellos.
- **Pasting**
  - "Bagging SIN remplazo"...
  - Cada ejemplo que pasa a formar parte de un subconjunto no puede volver a ser elegido para ese mismo subconjunto, aunque sí para otro.

Combinación de los resultados

- Podemos utilizar un sistema de votación.

Bagging

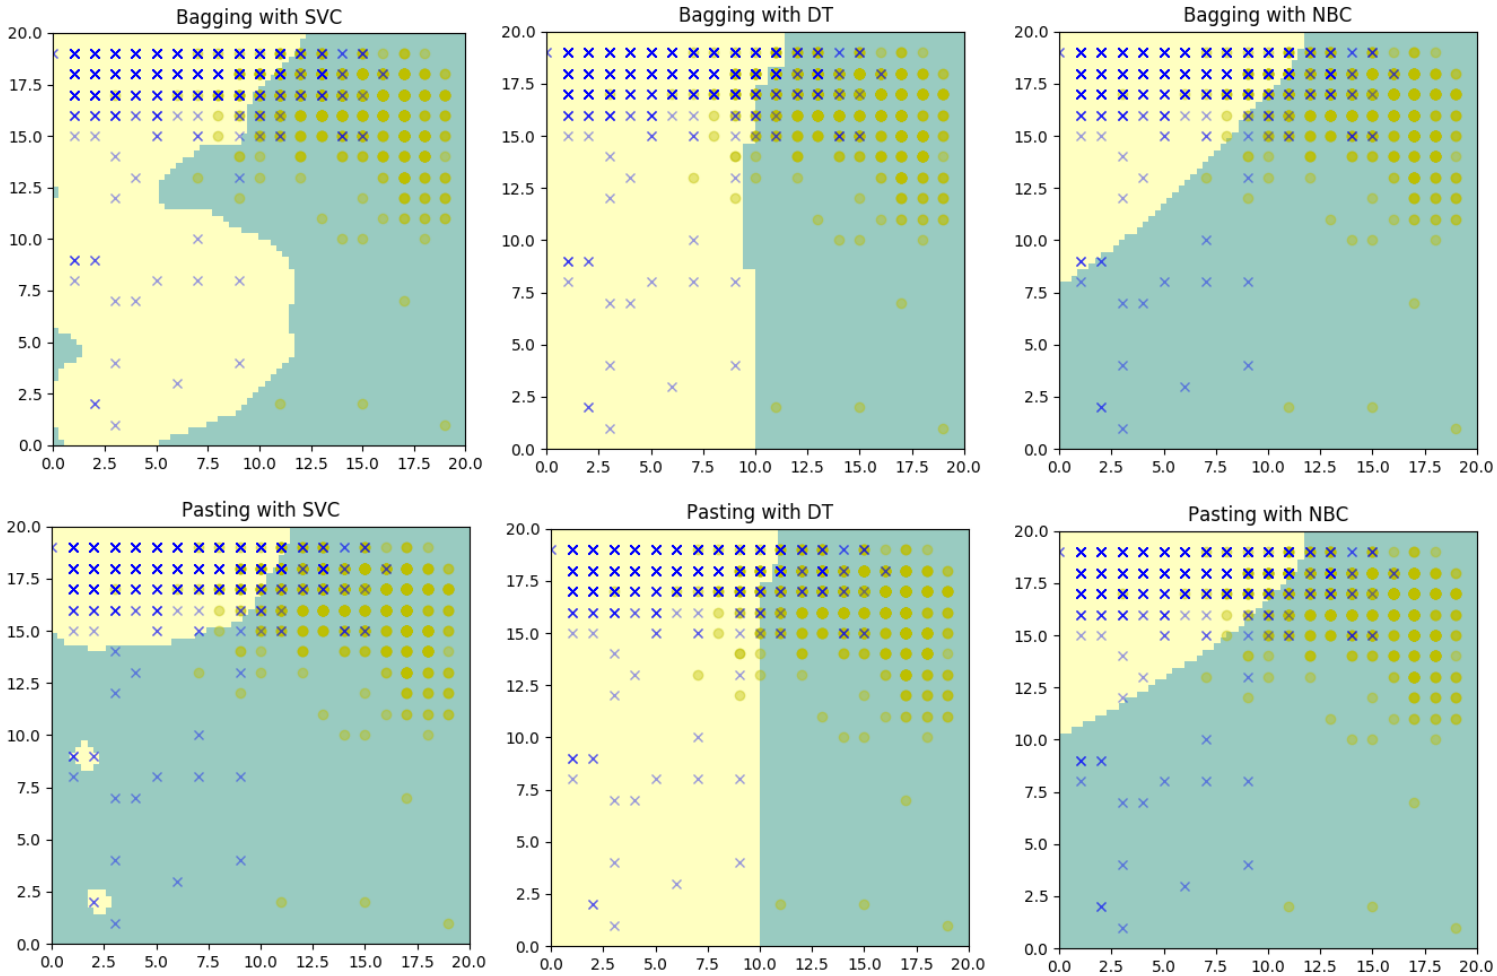

Figura: Comparativa de *bagging* vs. *pasting* con 3 clasificadores (SVM, DT y NBC). En todos los casos se utilizaron sólo 20 muestras y 100 clasificadores. [Fuente: Original de A. Cuesta]

Bagging

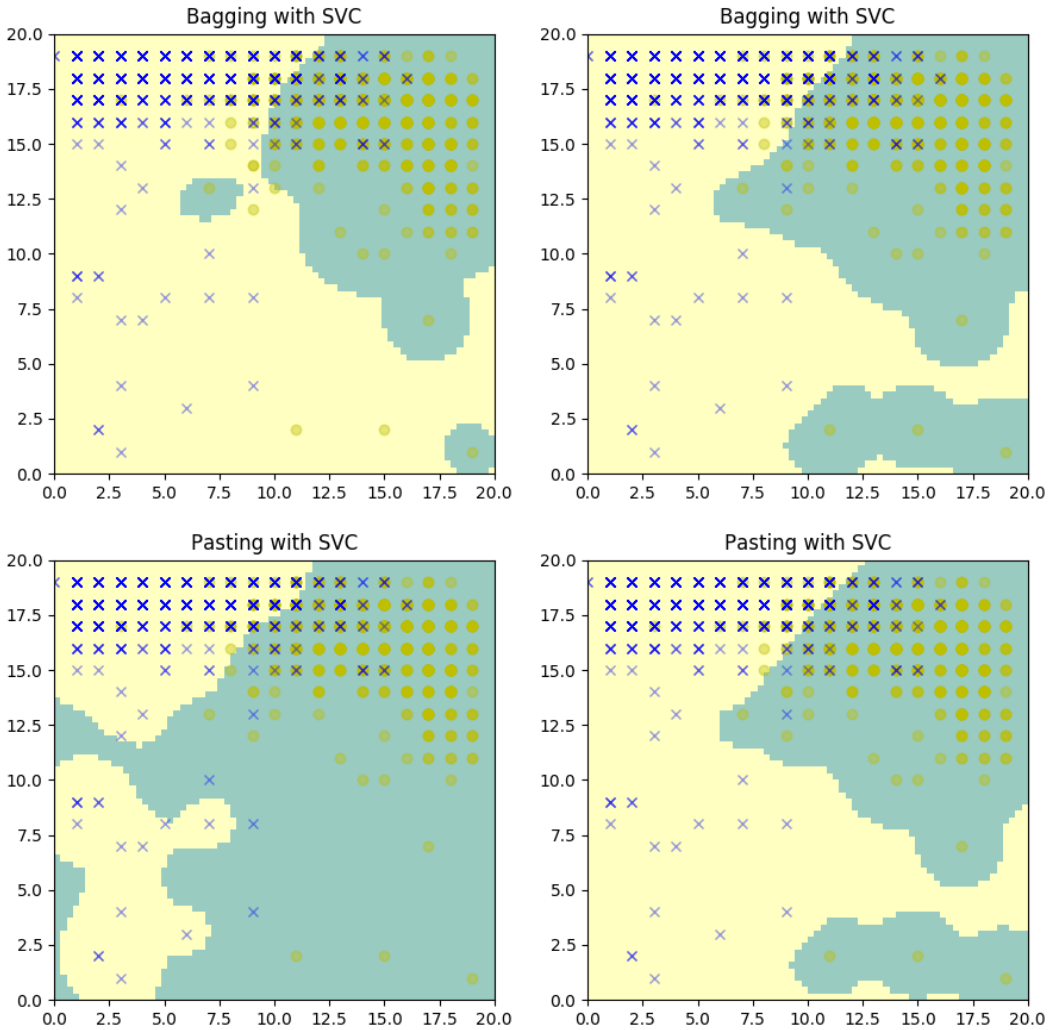

Figura: Comparativa de *bagging* (arriba) y *pasting* (abajo) con 10 clasificadores (izq.) y con 100 clasificadores (der.) [Fuente: Original de A. Cuesta]

Contenidos

Random Forests

- Bagging con árboles de decisión (DT).
- Utiliza DT muy sencillos, claramente subajustados, pero MUCHOS.
- Además, a la hora de crear cada DT, se seleccionan de manera **aleatoria** las características que se van a utilizar, con lo que se consigue una gran diversidad de árboles.
- Tiene un 2º resultado importante:
  proporciona una medida de las características más "importantes".

  (las características con mayor poder discriminador aparecen en nodos próximos a la raíz del árbol)

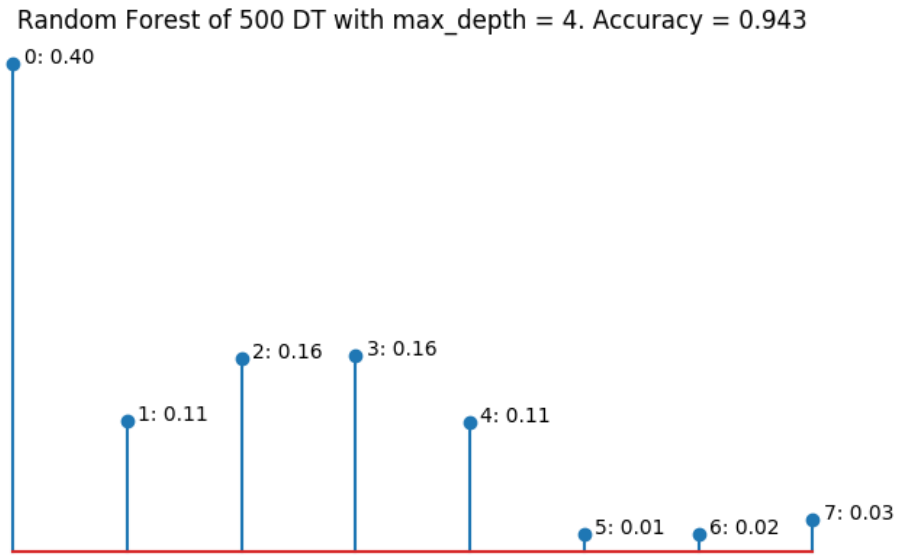

Figura: Obtención de la importancia de las características con RF.

Contenidos

Boosting

Objetivo

- To boost Impulsar, potenciar
- Lograr un clasificador "potente" a partir de una **secuencia** de entrenamientos de uno o varios clasificadores "débiles".

"Similar" al turbo: los gases (residuos) de la combustión, se utilizan para impulsar más aún al motor.

Boosting

AdaBoost

- Adaptive Boosting

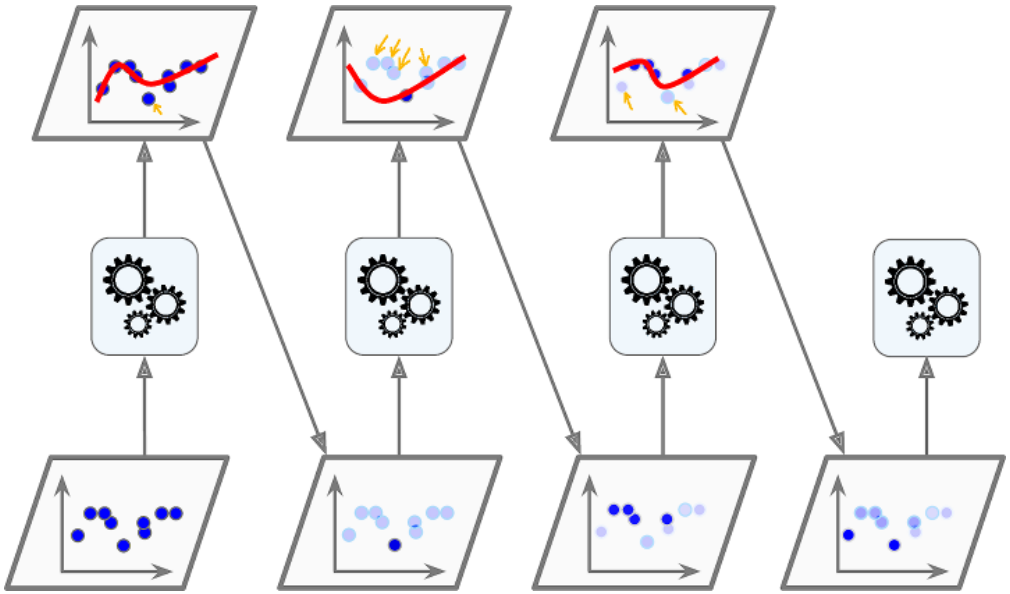

- Dado un conjunto de datos, ajustar un clasificador "sencillo"
  $\rightarrow$ Obtenemos errores (residuos)
- Ponderar los aciertos y los errores y volver a entrenar
  Regla de actualización de los pesos
- Repetir varias veces.
- Combinar todos los clasificadores obtenidos.

Boosting

AdaBoost

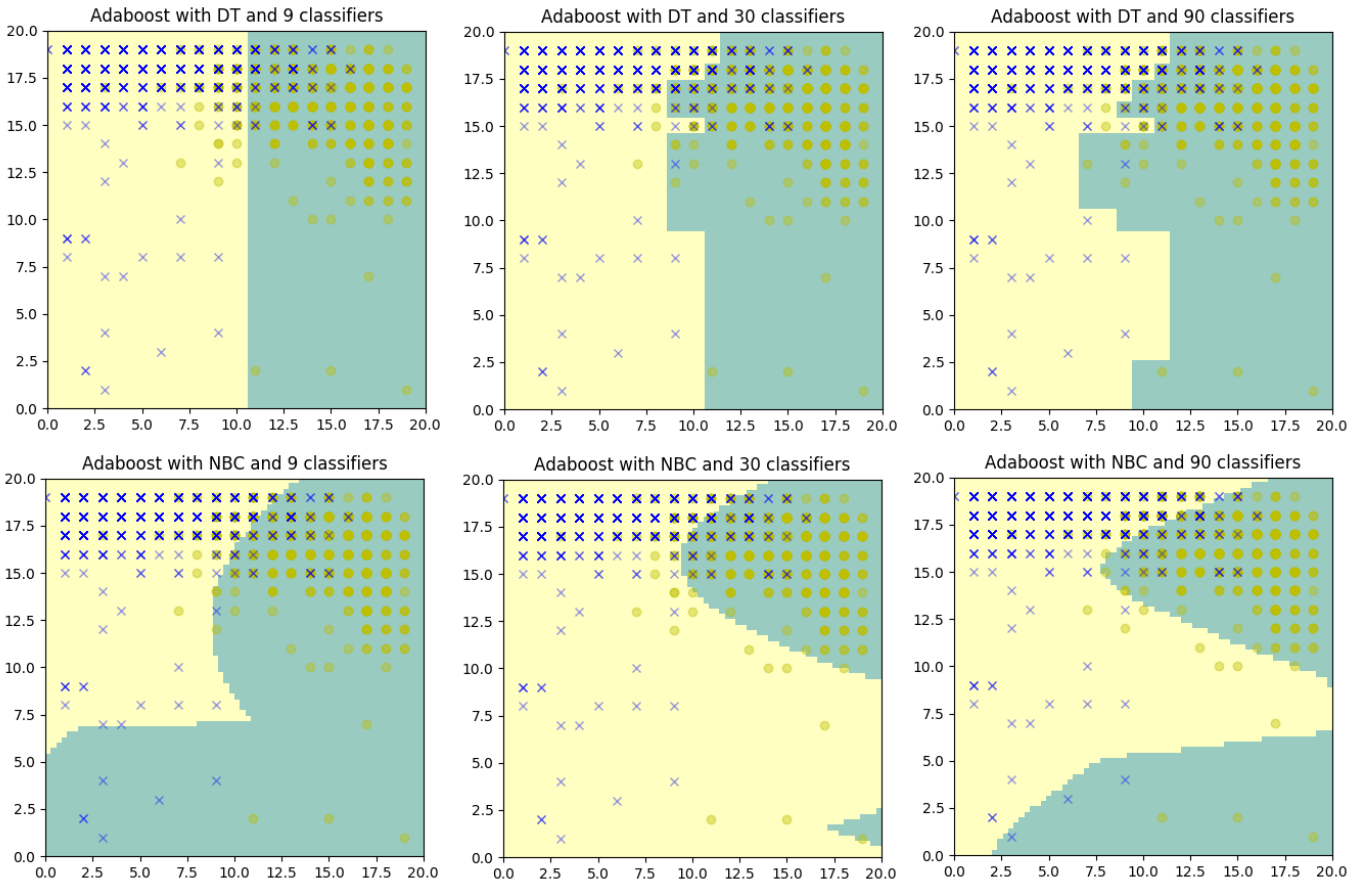

Figura: (Arriba) Adaboost con 9, 30 y 90 árboles de decisión de profundidad 1 y (abajo) con 9, 30 y 90 NBCs. [Fuente: Original de A. Cuesta]

Boosting

AdaBoost

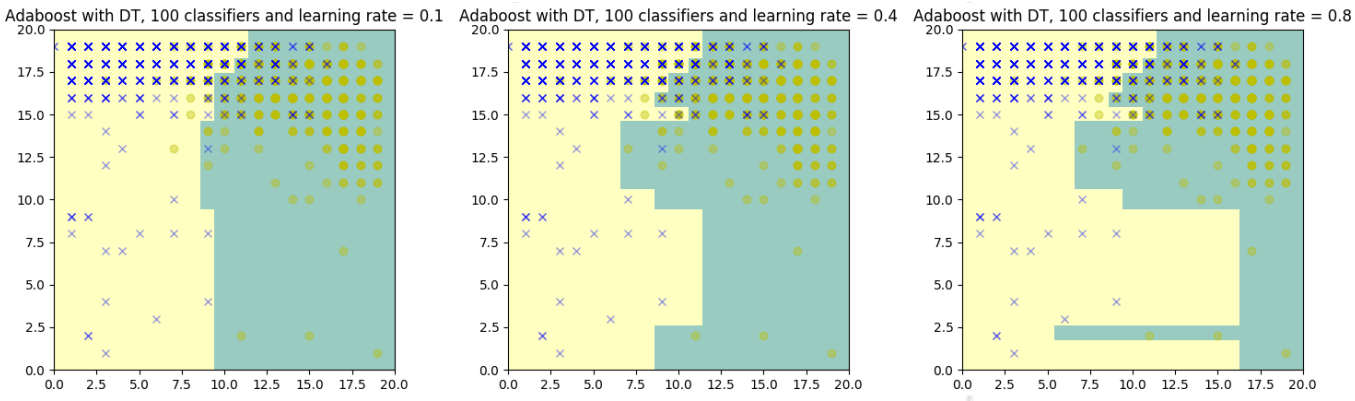

Figura: (Arriba) Adaboost con 100 árboles de decisión de profundidad 1 variando el ratio de aprendizaje: (izq.) 0.1, (centro) 0.4, (der.) 0.8. [Fuente: Original de A. Cuesta]

Boosting

Gradient Boosting

- Supongamos que existe la función de regresión perfecta $h^*(\mathbf{X}) = \mathbf{y}$
- Vamos a intentar obtenerla mediante aproximaciones sucesivas

$$h^* \simeq h_0 + h_1 + h_2 + \cdots$$

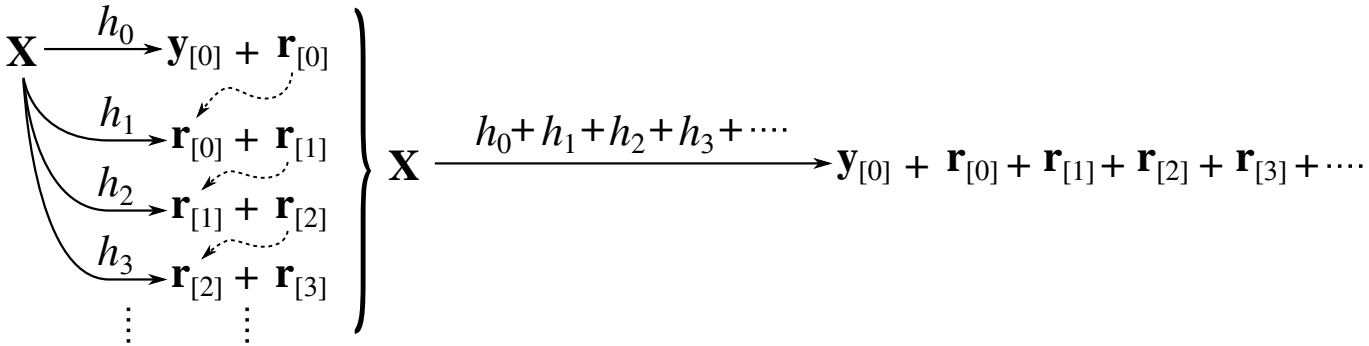

Figura: Aprendizaje de árboles de regresión con *gradient boosting*