

Reducción de la dimensionalidad

Alfredo Cuesta Infante

E. T. S. Ingeniería Informática
Universidad Rey Juan Carlos

Master Univ. en Visión Artificial
Reconocimiento de Patrones

Motivación

Motivación

Principal Component
Analysis (PCA)

Locally Linear
Embedding (LLE)

Linear Discriminant
Analysis (LDA)

Principal Component Analysis (PCA)

Locally Linear Embedding (LLE)

Linear Discriminant Analysis (LDA)

Motivación

Motivación

Principal Component
Analysis (PCA)

Locally Linear
Embedding (LLE)

Linear Discriminant
Analysis (LDA)

Principal Component Analysis (PCA)

Locally Linear Embedding (LLE)

Linear Discriminant Analysis (LDA)

Hemos visto técnicas de aumento de la dimensionalidad que nos permitían hacer clasificación no lineal, es decir más expresiva y general que la lineal:

- ▶ Ingeniería de características
- ▶ Transformaciones no lineales de las características
- ▶ Utilización de Kernels

entonces...




¿Para qué?

- ▶ Reduce el coste computacional, en ejecución y en memoria.
- ▶ Nos permite visualizar los datos cuando estos tienen alta dimensionalidad.
 - ▶ Las técnicas de visualización **no** son capaces de mostrar más de 6 o 7 características.
Por ej. en este sitio web se describen diferentes técnicas para mostrar hasta 6 dimensiones [↗](#)
- ▶ Puede facilitar la separación lineal.

¿Cómo?

- ▶ Eliminando características redundantes
- ▶ Eliminando características poco correladas con la etiqueta
- ▶ Proyectando a subespacios

Motivación



Reducción de la dimensionalidad

Alfredo Cuesta Infante

Motivación

Principal Component Analysis (PCA)

Locally Linear Embedding (LLE)

Linear Discriminant Analysis (LDA)

Ejemplo de selección por correlación

Reducción de la dimensionalidad

Alfredo Cuesta Infante

Motivación

Principal Component Analysis (PCA)

Locally Linear Embedding (LLE)

Linear Discriminant Analysis (LDA)

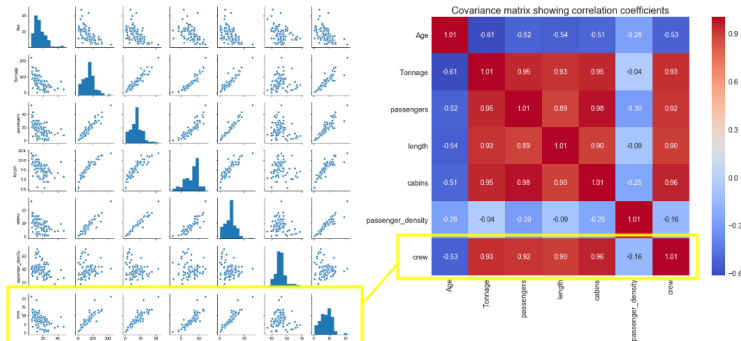


Figura: Si la etiqueta fuera la última columna de la tabla, entonces las características más relacionadas con ella son la 2ª, 3ª, 4ª y 5ª

Ejemplo de reducción por proyección

Reducción de la dimensionalidad

Alfredo Cuesta Infante

Motivación

Principal Component Analysis (PCA)

Locally Linear Embedding (LLE)

Linear Discriminant Analysis (LDA)




Figura: Reducción de 3 a 2 dimensiones proyectando sobre el subespacio que más información recoge

Motivación

Principal Component
Analysis (PCA)

Locally Linear
Embedding (LLE)

Linear Discriminant
Analysis (LDA)

Motivación

Principal Component Analysis (PCA)

Locally Linear Embedding (LLE)


Linear Discriminant Analysis (LDA)

Principal Component Analysis (PCA)

Reducción de la dimensionalidad

Alfredo Cuesta Infante

- Buscar la proyección que conserva la mayor varianza de los datos.



Motivación

Principal Component Analysis (PCA)

Locally Linear Embedding (LLE)

Linear Discriminant Analysis (LDA)

- Datos = \mathbf{X} , descomponiendo en (SVD) $\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$.
 $\mathbf{\Sigma}$ son los componentes principales, y las matrices se reordenan de tal manera que la diagonal de $\mathbf{\Sigma}$ esté ordenada de mayor a menor.
- Las columnas de \mathbf{V}^T son una base del espacio donde viven \mathbf{X}
- Con los n primeros tengo la base de un subespacio, y $\mathbf{X}_{\text{proy}} = \mathbf{X}\mathbf{W}$ es la proyección de los datos en esa base.
→ es decir, los datos con dimensión reducida.
- Con \mathbf{U} , \mathbf{V} y $\mathbf{\Sigma}$ podemos reconstruir \mathbf{X} a partir de cualquier \mathbf{X}_{proy} .

Principal Component Analysis (PCA)

Reducción de la dimensionalidad


Alfredo Cuesta Infante

Motivación


Principal Component Analysis (PCA)

Locally Linear Embedding (LLE)


Linear Discriminant Analysis (LDA)



(a)



(c)



(b)

First 8 principal components

[-0.24	0.49	0.79	-0.02	0.20	0.08	0.00	-0.14]
[0.01	0.01	0.07	0.53	-0.48	0.54	0.40	-0.00]
[-0.12	-0.02	-0.15	-0.48	0.32	0.22	0.75	0.00]
[-0.14	-0.03	-0.09	-0.38	-0.02	0.75	-0.50	0.02]
[0.04	-0.06	-0.11	-0.00	-0.02	0.00	-0.01	-0.98]
[-0.05	-0.84	0.43	0.13	0.27	0.07	-0.00	-0.00]
[-0.67	0.07	-0.35	0.47	0.42	0.03	-0.07	-0.00]
[-0.66	-0.18	0.07	-0.29	-0.59	-0.26	0.04	-0.01]

First 8 singular values

[259.1	233.7	221.8	192.6	179.4	160.5	149.8	77.6]
---------	-------	-------	-------	-------	-------	-------	-------

Explained Variance Ratio

[0.22	0.18	0.16	0.12	0.10	0.08	0.07	0.02]
--------	------	------	------	------	------	------	-------

Accumulated Explained Variance Ratio

[0.22	0.41	0.58	0.70	0.81	0.90	0.97	1.]
--------	------	------	------	------	------	------	-----

(d)

Figura: (a-b) '0' vs. '1' con los 2 y 3 primeros componentes principales. (c) Porcentaje de varianza explicado según se añaden componentes principales, en rojo, y su acumulado, en azul. (d) Resultados numéricos.

- ▶ Sea $\mathbf{K} = \mathbf{X}^T \mathbf{X} / (m - 1)$ la matriz de covarianza de los datos, $\mathbf{K} = \mathbf{W} \mathbf{\Lambda} \mathbf{W}^T$ su descomposición en autovalores, y $\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$ sea la SVD del conjunto de datos.
- ▶ Reescribimos $\mathbf{X} \mathbf{X}^T = (\mathbf{U} \mathbf{\Sigma} \mathbf{V}^T) (\mathbf{U} \mathbf{\Sigma} \mathbf{V}^T)^T = \mathbf{U} \mathbf{\Sigma} (\mathbf{V}^T \mathbf{V}) \mathbf{\Sigma} \mathbf{U}^T$.
- ▶ Como $\mathbf{V} \mathbf{V}^T = \mathbf{V}^T \mathbf{V} = \mathbf{1}$ nos queda $\mathbf{X} \mathbf{X}^T = \mathbf{U} \mathbf{\Sigma} \mathbf{\Sigma} \mathbf{U}^T = \mathbf{U} \mathbf{\Sigma}^2 \mathbf{U}^T$.
- ▶ Por tanto $\mathbf{X}^T \mathbf{X} / (m - 1) = \mathbf{W} \mathbf{\Lambda} \mathbf{W}^T = \mathbf{U} \mathbf{\Sigma}^2 \mathbf{U}^T / (m - 1)$.
- ▶ La matriz de autovalores de la descomposición de la covarianza es el cuadrado de la matriz de valores singulares del conjunto de datos, salvo por la constante.
- ▶ ¿Y si en vez de calcular $\mathbf{X}^T \mathbf{X}$ utilizamos un kernel $\mathcal{K}(\mathbf{X}, \mathbf{X}^T)$ que nos devuelva este resultado en otro espacio diferente?
- ▶ Obtenemos *Kernel-PCA*
 - ▶ Infinitos vectores principales \rightarrow ya no “existe” la reconstrucción.
Python tiene un método de reconstrucción basado en aprender la función de mapeo del conjunto de datos original al conjunto de datos proyectado.





Figura: Proyección del conjunto de datos '0' vs. '1' en los 2 y 3 primeros componentes principales con un PCA de kernel RBF, con parámetro 0.01.
[Fuente: Original de A. Cuesta]

Motivación

Motivación

Principal Component
Analysis (PCA)

Locally Linear
Embedding (LLE)

Linear Discriminant
Analysis (LDA)

Principal Component Analysis (PCA)


Locally Linear Embedding (LLE)

Linear Discriminant Analysis (LDA)

Locally Linear Embedding (LLE)

Objetivo. Proyectar nuestros puntos sobre una **variedad** *manifold*

- Una variedad es un espacio donde, a escala local, se conservan las propiedades euclídeas. *Por ej. el mapa de una ciudad*



1. Identificar los k vecinos más próximos de cada ejemplo $\mathbf{x}^{(i)}$,
2. Se reconstruye dicho ejemplo mediante una función lineal de los vecinos

$$\mathbf{x}_{\text{rec}}^{(i)} = \sum_{j=1}^k w_{ij}^* \mathbf{x}^{(j)}, \text{ tal que } \mathbf{W}^* = \arg \min_{\mathbf{W}} \sum_{i=1}^m \left\| \mathbf{x}^{(i)} - \sum_{j=1}^k w_{ij} \mathbf{x}^{(j)} \right\|^2$$

Los pesos se normalizan de manera que $\sum_{j=1}^m w_{ij} = 1, i = 1, \dots, m$.

3. Sea $\mathbf{Z} = \{\mathbf{z}^{(i)}\}$ el mapeo de $\mathbf{X} = \{\mathbf{x}^{(i)}\}$:

$$\mathbf{Z}^* = \arg \min_{\mathbf{Z}} \sum_{i=1}^m \left\| \mathbf{z}^{(i)} - \sum_{j=1}^k w_{ij}^* \mathbf{z}^{(j)} \right\|^2$$

Locally Linear Embedding (LLE)

Reducción de la dimensionalidad

Alfredo Cuesta Infante

Motivación

Principal Component Analysis (PCA)

Locally Linear Embedding (LLE)

Linear Discriminant Analysis (LDA)




Figura: Proyección del conjunto de datos '0' vs. '1' en una variedad 2D (izq.) y en una 3D (der.) mediante LLE estandar, con 50 vecinos y método 'auto'.

[Fuente: Original de A. Cuesta]

Motivación

Principal Component
Analysis (PCA)

Locally Linear
Embedding (LLE)

Linear Discriminant
Analysis (LDA)

Motivación

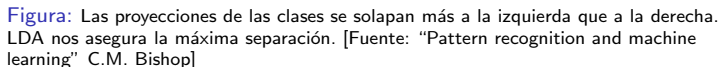
Principal Component Analysis (PCA)

Locally Linear Embedding (LLE)

Linear Discriminant Analysis (LDA)

- ▶ **Asumiendo que**
 - ▶ tenemos dos clases,
 - ▶ los ejemplos de cada clase tienen distribución MVN,
 - ▶ la covarianza es la misma para todas las MVN
- ➔ hiperplano discriminante = LDA

Linear Discriminant Analysis (LDA)



◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡ ≡ ≡ ↺ 🔍 ↻